



Projet de Modélisation et Machine Learning

-

Diagramme HR

Sara E. VELASCO CALDERON
Monija SIVARAJAH

Master 1 Physique fondamentale et applications

1. Introduction et contexte

2. Objectif du projet

3. Données utilisées

4. Apprentissage non supervisé

1. Méthodologie d'analyse

2. Résultats et analyse


5. Apprentissage supervisé

1. Méthodologie d'analyse

2. Résultats et analyse

6. Conclusion et pistes d'amélioration

Introduction et contexte




Source : Wikipédia

❖ *Diagramme HR :*

- Magnitude absolue (axe vertical)
- Indice de couleur B-V (axe horizontal)
- Permet de distinguer les principales étapes de l'évolution des étoiles

Objectif du projet et données utilisées


- Segmenter automatiquement les étoiles selon leur position sur le diagramme HR afin de révéler les différentes populations stellaires



Source : Catalogue Hipparcos (ESA) récupéré sur Kaggle


Méthodologie d'analyse

Apprentissage non supervisé



Méthodologie d'analyse – Prétraitement et PCA

Apprentissage non supervisé



- Sans PCA
- Avec PCA

K-Means

DBSCAN


GMM

Résultats et analyse – K-Means

Sans PCA


Apprentissage non supervisé

Entrainement



Score : 0.075

Test







Score : 0.076

Résultats et analyse – K-Means

Avec PCA

Analyse PCA et K-Means (Entraînement et Test)
2 composantes, 4 clusters

Apprentissage non supervisé







2 composantes

Résultats et analyse – K-Means

Avec PCA

Analyse PCA et K-Means (Entraînement et Test)
5 composantes, 4 clusters

Apprentissage non supervisé







5 composantes

Résultats et analyse – K-Means

Avec PCA

Analyse PCA et K-Means (Entrainement et Test)
20 composantes, 4 clusters

Apprentissage non supervisé




20 composantes

Résultats et analyse – DBSCAN

Sans PCA

Avec l'ensemble des données

Apprentissage non supervisé





Score : 0.668

Résultats et analyse – DBSCAN

Sans PCA

Avec la séparation Train/Test

Apprentissage non supervisé







- DBSCAN a attribué tous les points au cluster -1 (bruit).
- Le Silhouette Score ne peut pas être calculé, car il nécessite au moins deux clusters valides.

Résultats et analyse – DBSCAN

Avec PCA

Avec la séparation Train/Test

Apprentissage non supervisé




Résultats et analyse – GMM

Sans PCA


Apprentissage non supervisé

Entrainement



Score : 0.189



Test




Score : -0.005

Résultats et analyse – GMM


Avec PCA



Apprentissage non supervisé




Score : 0.169



Score : 0.066

Méthodologie d'analyse


Apprentissage supervisé




Résultats et analyse – Labellisation des données

Apprentissage supervisé

Tracé des courbes de chaque type
d'étoiles




Labellisation à partir de ces courbes




Résultats et analyse – Entraînement et prédiction

Apprentissage supervisé

Visualisation du Train pour les
données labellisées
(Courbe « théorique »)




Visualisation de la prédiction sur les
données de Test



Résultats et analyse – Évaluation du modèle


Apprentissage supervisé




	precision	recall	f1-score	support
Géante	1.00	1.00	1.00	11630
Naine blanche	1.00	0.25	0.40	4
Supergéante	0.98	0.89	0.93	451
Séquence principale	1.00	1.00	1.00	20249
accuracy			1.00	32334
macro avg	0.99	0.78	0.83	32334
weighted avg	1.00	1.00	1.00	32334

Comparaison

Courbe « théorique »



K-Means, 2 composantes, Train



*Conclusion
et pistes
d'améliorations*

Quel est le modèle le plus performant ?

K-Means

- Augmentation du silhouette score suite à la PCA
- Meilleur silhouette score pour 2 composantes principales
- Pas de clusters distinguables pour supergéantes et naines blanches

DBSCAN

- On a bien 4 clusters + un cluster de bruit avec l'ensemble des données
- Score de 0.668 avec l'ensemble des données
- Aucun cluster (sauf le bruit) avec la séparation Train/Test
- Avec PCA : 6 clusters incorrects
- Disproportion des clusters

GMM

- Silhouette score différent entre Train et Test
→ pas de généralisation du modèle
- Score plus faible que K-Means

Quel est le modèle le plus performant ?

K-Means

- Augmentation du silhouette score suite à la PCA
- Meilleur silhouette score pour 2 composantes principales
- Pas de clusters distinguables pour supergéantes et naines blanches

Meilleur modèle

DBSCAN

- On a bien 4 clusters + un cluster de bruit avec l'ensemble des données
- Score de 0.668 avec l'ensemble des données
- Aucun cluster (sauf le bruit) avec la séparation Train/Test
- Avec PCA : 6 clusters incorrects
- Disproportion des clusters

GMM

- Silhouette score différent entre Train et Test
→ pas de généralisation du modèle
- Score plus faible que K-Means

*Merci de votre
attention*